

INFERÊNCIA DE REDE NEURAL DENSE (MLP FORWARD PASS)

Alunos: Paulo Henrique e Kaik Henrique
Instituto Federal Goiano – Campus Iporá

PROBLEMA

- Inferência de MLP (forward pass)
- Dataset: MNIST / Fashion-MNIST
- Principal custo: multiplicação de matrizes (GEMM)
- Limitação da CPU em paralelismo

OBJETIVO


IMPLEMENTAR MLP DO ZERO:

- CPU SEQUENCIAL
- GPU CUDA CUSTOMIZADA
- PYTORCH (BASELINE OTIMIZADO)

COMPARAR DESEMPENHO

MÉTRICAS

- TEMPO
- SPEEDUP
- ESCALABILIDADE (BATCH SIZE)



ARQUITETURA E TEORIA

CPU: EXECUÇÃO SEQUENCIAL

GPU: MODELO SIMT (CUDA)


• THREADS, BLOCOS, GRID

HIERARQUIA DE MEMÓRIA

• GLOBAL VS SHARED

REGIME

• MEMORY-BOUND VS COMPUTE-BOUND (ROOFLINE)



IMPLEMENTAÇÃO


MLP: 784 → 128 → 64 → 10

CPU

- KERNEL PARALELO (1 THREAD POR ELEMENTO)
- MAPEAMENTO (BLOCOS 2D)
- CUDAMALLOC / CUDAMEMCPY

PYTORCH

- USO DE CUBLAS AUTOMATICAMENTE



METODOLOGIA EXPERIMENTAL


GOOGLE COLAB (GPU TESLA T4)

BATCH SIZES: 1, 64, 256, 1024

MEDIÇÃO:

- CPU: CHRONO/TIME
- GPU: CUDAEVENT

COMPARAÇÃO DIRETA DE TEMPOS





RESULTADOS E CONCLUSÃO

- GPU SUPERA CPU EM BATCHES GRANDES
- PYTORCH > CUDA CUSTOM > CPU
- SPEEDUP CRESCE COM BATCH SIZE
- GARGALO: MEMÓRIA + OVERHEAD INICIAL

REFERÊNCIAS

- HAYKIN (2009) — REDES NEURAIS
- KIRK & HWU (2016) — CUDA E PARALELISMO MASSIVO
- LECUN, BENGIO & HINTON (2015) — DEEP LEARNING
- PASZKE ET AL. (2019) — PYTORCH
- WILLIAMS ET AL. (2009) — MODELO ROOFLINE
- SHI ET AL. (2016) — BENCHMARKING CPU VS GPU



OBRIGADO!